



Министерство науки и высшего образования Российской Федерации
Федеральное государственное автономное образовательное учреждение
высшего образования
«Московский государственный технический университет
имени Н.Э. Баумана
(национальный исследовательский университет)»
(МГТУ им. Н.Э. Баумана)

ФАКУЛЬТЕТ ИНФОРМАТИКА И СИСТЕМЫ УПРАВЛЕНИЯ

КАФЕДРА СИСТЕМЫ ОБРАБОТКИ ИНФОРМАЦИИ И УПРАВЛЕНИЯ

РАСЧЕТНО-ПОЯСНИТЕЛЬНАЯ ЗАПИСКА
К НАУЧНО-ИССЛЕДОВАТЕЛЬСКОЙ РАБОТЕ ПО
ОБРАБОТКЕ И АНАЛИЗУ ДАННЫХ

НА ТЕМУ:

***Исследование моделей предиктивного анализа
для оптимизации пропускной способности
точек контроля доступа***

Студент ИУ5-33М
(Группа)

А.П. Костарев
(И.О. Фамилия)

Руководитель курсовой работы

Ю.Е. Гапанюк
(И.О. Фамилия)

2025 г.

Министерство науки и высшего образования Российской Федерации
Федеральное государственное автономное образовательное учреждение
высшего образования
«Московский государственный технический университет имени Н.Э. Баумана
(национальный исследовательский университет)»
(МГТУ им. Н.Э. Баумана)

УТВЕРЖДАЮ
Заведующий кафедрой ИУ5
(Индекс)
В.И. Терехов
(И.О. Фамилия)
«08» сентября 2025 г.

ЗАДАНИЕ на выполнение курсовой работы

по дисциплине НИР по обработки и анализу данных

Студентка группы ИУ5-33М

Костарев Александр Павлович
(Фамилия, имя, отчество)

Тема курсовой работы Исследование моделей предиктивного анализа для оптимизации пропускной способности точек контроля доступа

Направленность КР (учебная, исследовательская, практическая, производственная, др.)
УЧЕБНАЯ

Источник тематики (кафедра, предприятие, НИР) КАФЕДРА

График выполнения работы: 25% к нед., 50% к нед., 75% к нед., 100% к нед.

Задание Провести анализ существующих моделей предиктивного анализа с точки зрения их применимости для оптимизации пропускной способности точек контроля доступа в СКУД университета. Провести классификацию и сравнительный анализ моделей, оценить их соответствие особенностям работы СКУД и сформулировать практические рекомендации по выбору и применению моделей без их самостоятельной разработки

Оформление курсовой работы:

Расчетно-пояснительная записка на листах формата А4.

Дата выдачи задания «15» сентября 2025 г.

Руководитель курсовой работы

Ю.Е. Гапанюк

(Подпись, дата)

(И.О. Фамилия)

Студент

А.П. Костарев

(Подпись, дата)

(И.О. Фамилия)

Примечание: Задание оформляется в двух экземплярах: один выдается студенту, второй хранится на кафедре

СОДЕРЖАНИЕ

ВВЕДЕНИЕ	4
1 Теоретические основы СКУД и предиктивного анализа.....	6
1.1 Системы контроля и управления доступом в образовательных учреждениях	6
1.2 Понятие пропускной способности и показатели эффективности КПП	
9	
1.3 Предиктивная аналитика в задачах управления потоками и очередями	
12	
2 Модели предиктивного анализа и их применимость к СКУД	
университета	17
2.1 Классы моделей предиктивного анализа	17
2.2 Обзор и краткая характеристика основных моделей.....	20
2.3 Критерии оценки и сравнения моделей для задач СКУД	24
2.4 Оценка применимости моделей для оптимизации пропускной способности СКУД университета	27
2.5 Рекомендации по выбору моделей для практического использования .	31
ЗАКЛЮЧЕНИЕ.....	34
СПИСОК ИСПОЛЬЗУЕМЫХ ИСТОЧНИКОВ.....	36

ВВЕДЕНИЕ

В современных условиях цифровизации образовательных процессов системы контроля и управления доступом (СКУД) становятся неотъемлемой частью инфраструктуры университета, обеспечивая не только безопасность, но и сбор значительных объёмов данных о перемещении студентов и сотрудников. При увеличении числа пользователей и усложнении расписания занятий особенно остро встаёт проблема формирования очередей и перегрузки точек контроля доступа в часы пик, что снижает комфорт и может приводить к нарушениям учебного процесса. В этих условиях возрастаёт потребность в инструментах, позволяющих не просто фиксировать текущую ситуацию, а прогнозировать будущую нагрузку и заблаговременно предпринимать меры по её сглаживанию, что делает применение предиктивной аналитики в СКУД университета особенно актуальным.

Предиктивный анализ, основанный на использовании статистических методов и алгоритмов интеллектуальной обработки данных, предоставляет возможность выявлять закономерности в исторических данных, оценивать влияние различных факторов и строить прогнозы интенсивности потоков через точки контроля доступа. Однако существующие модели предиктивного анализа развиваются преимущественно в контексте промышленности, транспорта, ритейла и других отраслей, тогда как специфика вузовской среды — расписание занятий, сессии, массовые мероприятия, каникулы — требует отдельного рассмотрения применимости этих моделей. Поэтому необходим систематический анализ уже разработанных подходов с точки зрения их адаптации к задачам оптимизации пропускной способности СКУД университета без создания новых алгоритмов.

Целью данной курсовой работы является анализ существующих моделей предиктивного анализа с точки зрения их применимости для оптимизации пропускной способности точек контроля доступа в СКУД университета. Для достижения поставленной цели требуется решить следующие основные задачи:

- исследовать теоретические основы предиктивной аналитики и систем контроля и управления доступом в образовательных учреждениях;
- провести обзор, классификацию и сравнительный анализ основных классов моделей предиктивного анализа, применимых к задачам прогнозирования потоков и очередей;
- определить требования к моделям, обусловленные особенностями функционирования СКУД университета и доступностью данных;
- оценить применимость различных моделей к задачам оптимизации пропускной способности точек контроля доступа и выявить наиболее перспективные подходы;
- сформулировать практические рекомендации по выбору и использованию существующих моделей предиктивного анализа для повышения эффективности работы СКУД университета.

1 Теоретические основы СКУД и предиктивного анализа

В современных образовательных учреждениях системы контроля и управления доступом (СКУД) играют ключевую роль в обеспечении безопасности, управлении потоками людей и учёте посещаемости. С ростом масштабов университетов, увеличением количества студентов и сотрудников, а также усложнением расписания занятий возрастаёт потребность в централизованных и интеллектуальных системах, позволяющих контролировать перемещения, разграничивать права доступа и получать аналитическую информацию для управленческих решений. Для вузов особенно важно не только ограничить доступ в отдельные помещения и зоны, но и сделать этот процесс максимально удобным и быстрым для пользователей, минимизируя очереди и задержки на входе в корпуса.

1.1 Системы контроля и управления доступом в образовательных учреждениях

Системы контроля и управления доступом в вузах предназначены для решения нескольких взаимосвязанных задач: обеспечения безопасности, разграничения прав доступа, учёта посещаемости и поддержки организационных процессов. СКУД позволяет ограничивать доступ посторонних на территорию университета, дифференцировать права входа в корпуса, лаборатории, общежития и иные помещения, а также автоматически регистрировать факты входа и выхода пользователей. Это создаёт основу не только для физической безопасности, но и для аналитики, например, анализа посещаемости занятий или загрузки отдельных зданий.

Архитектура СКУД в образовательных учреждениях обычно имеет многоуровневый характер и включает следующие основные элементы: устройства идентификации и исполнительные устройства на точках доступа, контроллеры, коммуникационную сеть и центральный сервер с программным обеспечением. На нижнем уровне размещаются считыватели и средства записи, обеспечивающие непосредственное взаимодействие с пользователем и управление проходом. На среднем уровне работают контроллеры, которые обрабатывают сигналы от устройств, принимают решения о предоставлении доступа, могут хранить локальные базы прав доступа и журналов событий. Верхний уровень представлен сервером СКУД и рабочими местами операторов, где осуществляется конфигурирование системы, управление правами доступа, мониторинг событий и формирование отчётности.

К основным компонентам СКУД в вузах относятся:

- идентификаторы пользователей (бесконтактные карты, брелоки, мобильные идентификаторы, биометрические данные);
- считыватели на входах в корпуса, аудитории, лаборатории, общежития;
- турникеты, электромеханические замки, шлюзовые кабины и другие исполнительные устройства;
- контроллеры доступа, объединённые в локальную сеть;
- серверное программное обеспечение с базой данных пользователей, прав доступа и журналами событий.

Назначение этих компонентов — обеспечить связную цепочку: от идентификации пользователя и проверки его прав до физического разрешения или запрета прохода, а также фиксации результата в системе. В учебных заведениях нередко СКУД интегрируется с информационными системами университета, системами электронного журнала, учёта рабочего времени и системами видеонаблюдения, что расширяет её функциональные возможности.

Типы точек контроля доступа в вузах разнообразны и зависят от назначения зоны и требуемого уровня безопасности. На входах в учебные корпуса часто используются турникеты (ростовые, трипод, калитки), обеспечивающие дозированный пропуск людей и позволяющие формировать контролируемый поток. Для аудиторий, лабораторий и административных помещений чаще применяются двери с электромеханическими или электромагнитными замками и считывателями карт, поскольку там требуется ограничение доступа, но нет постоянного интенсивного потока людей. В общежитиях и на въездах на территорию могут использоваться шлагбаумы и калитки с контролем по тем же идентификаторам.

Каждый тип точки контроля доступа имеет свои характеристики, влияющие на общую пропускную способность и удобство пользования. Например, турникеты обеспечивают высокий уровень контроля и возможность точного учёта проходов, но при большой интенсивности потоков могут формировать очереди. Двери с электрозамками позволяют быстрее пропускать людей при открытом состоянии, однако хуже контролируют поштучный проход. Шлагбаумы и ворота ориентированы на транспорт и характеризуются иной спецификой пропускной способности.

Типовые режимы работы точек контроля доступа в образовательных учреждениях зависят от времени суток, учебного расписания и категорий пользователей. В утренние часы до начала занятий и в периоды смены пар наблюдаются пиковые нагрузки на входные турникеты корпусов, когда основной поток студентов и преподавателей проходит в ограниченные промежутки времени. В течение дня интенсивность потоков обычно снижается и распределяется более равномерно, с небольшими всплесками перед отдельными занятиями или мероприятиями. В вечернее время, в выходные и во время каникул режим работы может меняться, часть точек доступа переводится в режим ограниченного доступа или полностью закрывается.

Для эффективного управления такими режимами требуется не только жёстко заданное расписание открытия и закрытия точек доступа, но и возможность гибкого реагирования на фактическую или прогнозируемую нагрузку. Именно здесь в перспективе применимы методы предиктивного анализа, позволяющие заблаговременно оценивать ожидаемую интенсивность потоков и адаптировать конфигурацию работы СКУД.

1.2 Понятие пропускной способности и показатели эффективности КПП

Пропускная способность точки контроля доступа в контексте университета понимается как максимальное количество пользователей, которое может пройти через данную точку за единицу времени при соблюдении заданных требований безопасности и комфортности. Формально пропускную способность можно представить как

$$C = \frac{N}{T},$$

где C — пропускная способность, N — количество пользователей, прошедших через точку доступа, T — интервал времени. Для турникетов этот показатель обычно выражается в людях в минуту или в час при определённом режиме работы и типе идентификации. Пропускная способность определяется совокупностью технических характеристик оборудования, логики работы программного обеспечения, организации потоков и особенностей поведения пользователей.

На пропускную способность в условиях университета влияет ряд факторов технического, организационного и поведенческого характера. К техническим факторам относятся скорость срабатывания считывателя, время проверки прав доступа и время открытия/закрытия исполнительного устройства. В простейшем приближении время обслуживания одного пользователя можно задать как

$$t_{обс} = t_{ид} + t_{проверки} + t_{мех},$$

где $t_{\text{ид}}$ — время предъявления идентификатора, $t_{\text{проверки}}$ — время обработки и принятия решения системой, $t_{\text{мех}}$ — время срабатывания исполнительного устройства. Тогда пропускная способность при равномерном потоке можно оценить как

$$C \approx \frac{1}{t_{\text{обс}}}$$

Временные факторы особенно существенны для вузов, поскольку потоки пользователей сильно зависят от расписания занятий, сессий и мероприятий. Можно рассматривать интенсивность входящего потока как функцию времени $\lambda(t)$, описывающую среднее число пользователей, приходящих к точке доступа за единицу времени. В часы пик $\lambda(t)$ резко возрастает, часто приближаясь к максимально возможной пропускной способности C , что ведёт к образованию очередей. В модели массового обслуживания при интенсивности потока λ и пропускной способности (обслуживания) μ для одной линии важным условием устойчивости системы является неравенство $\lambda < \mu$.

Для оценки эффективности работы контрольно-пропускных пунктов используются различные количественные показатели. Одним из ключевых является среднее время ожидания пользователя в очереди перед точкой доступа, которое можно обозначить как W_q . В простейшей системе с одним каналом и пуассоновским входящим потоком (модель $M/M/1$) при интенсивности потока λ и интенсивности обслуживания μ среднее время ожидания определяется формулой

$$W_q = \frac{\lambda}{\mu(\mu - \lambda)}$$

при условии $\lambda < \mu$. Это выражение показывает, что по мере приближения λ к μ время ожидания резко возрастает, что для вузовских КПП проявляется в виде длинных очередей перед началом занятий.

Другим важным показателем является средняя длина очереди L_q , то есть среднее число пользователей, ожидающих прохода. В той же модели $M/M/1$ она может быть выражена как

$$L_q = \frac{\lambda^2}{\mu(\mu - \lambda)}.$$

Коэффициент загрузки точки контроля доступа отражает степень использования её пропускной способности и часто обозначается как ρ . Для одной линии обслуживания при интенсивности потока λ и интенсивности обслуживания μ он задаётся формулой

$$\rho = \frac{\lambda}{\mu}.$$

Для комплексной характеристики работы КПП используется показатель уровня сервиса, который может определяться по-разному в зависимости от требований университета. Одним из вариантов является вероятность того, что время ожидания не превысит заданного порогового значения $W_{\text{доп}}$. Если обозначить это событие как $P(W_q \leq W_{\text{доп}})$, то уровень сервиса S может быть интерпретирован как

$$S = P(W_q \leq W_{\text{доп}}).$$

Использование перечисленных метрик в совокупности позволяет сформировать целостное представление о работе системы контроля доступа и выявить её слабые места. На основе измерений W_q , L_q , ρ и оценки уровня сервиса S возможно построение математических и предиктивных моделей поведения потоков пользователей. Эти модели дают возможность прогнозировать будущие состояния КПП при различных сценариях (изменение расписания, увеличение контингента, проведение массовых мероприятий) и заранее принимать решения по изменению конфигурации: увеличению числа активных линий прохода, перераспределению потоков между входами или корректировке расписания.

Таким образом, понятие пропускной способности и система показателей эффективности КПП образуют теоретическую основу для применения предиктивного анализа в задачах оптимизации работы СКУД университета. Формальное описание ключевых параметров и использование математических моделей массового обслуживания позволяют переходить от качественных наблюдений к количественным оценкам и обоснованным управленческим решениям.

1.3 Предиктивная аналитика в задачах управления потоками и очередями

Предиктивная аналитика представляет собой совокупность методов статистики и интеллектуального анализа данных, позволяющих на основе исторических наблюдений строить прогноз будущих значений ключевых показателей и оценивать вероятность наступления событий. В задачах управления потоками людей и очередями её цель — заранее оценивать нагрузку на элементы инфраструктуры (турникеты, КПП, кассы, стойки регистрации) и предотвращать перегрузки, а не только фиксировать уже сложившиеся очереди. Для СКУД университета это означает прогнозирование числа проходов через точки контроля доступа во времени и заблаговременную идентификацию потенциальных пиков.

Формально можно рассматривать временной ряд интенсивности проходов $\{y_t\}$, где y_t — количество пользователей, прошедших через точку доступа за интервал времени t . Задача предиктивной аналитики заключается в построении модели

$$\hat{y}_{t+h} = f(y_t, y_{t-1}, \dots, X_t),$$

где \hat{y}_{t+h} — прогноз на горизонт h , а X_t — вектор дополнительных факторов (день недели, номер пары, наличие мероприятия и др.).

Классический процесс применения предиктивной аналитики включает несколько этапов. На этапе сбора данных формируется выборка исторических наблюдений: логи проходов СКУД, расписание, календарь мероприятий, дополнительные сведения (например, каникулы, сессии). Далее выполняется предобработка: очистка, устранение дубликатов, заполнение пропусков, агрегация по выбранному шагу времени (например, 5, 10 или 60 минут). Результат можно представить как таблицу наблюдений $\{(X_t, y_t)\}_{t=1}^T$, где T — длина исторического периода.

На этапе формирования признаков исходные данные преобразуются в набор объясняющих переменных. Например, можно ввести бинарные или категориальные признаки для дня недели, признаковую функцию наличия учебных занятий в корпусе в соответствующий интервал, индикаторы сессий, массовых мероприятий и т.п. Формально вектор признаков можно записать как

$$X_t = (x_{t,1}, x_{t,2}, \dots, x_{t,k}),$$

где каждый компонент описывает отдельный фактор (календарный, организационный и др.).

Далее выбирается и обучается модель прогнозирования. В случае регрессионного подхода зависимость между интенсивностью потока и факторами может быть описана, например, линейной моделью:

$$y_t = \beta_0 + \sum_{i=1}^k \beta_i x_{t,i} + \varepsilon_t,$$

где β_i — коэффициенты влияния факторов, а ε_t — случайная ошибка. Для моделей временных рядов, таких как ARIMA, динамика может задаваться в виде

$$\phi(B)(y_t - \mu) = \theta(B)\varepsilon_t,$$

где B — оператор сдвига, $\phi(B)$ и $\theta(B)$ — полиномы авторегрессии и скользящего среднего соответственно.

Качество модели оценивается по метрикам ошибки прогнозирования.

Одна из распространённых метрик — средняя абсолютная ошибка (*MAE*):

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|,$$

где y_i — фактические значения, \hat{y}_i — прогнозы. Также применяется среднеквадратичная ошибка (*RMSE*):

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2},$$

которая сильнее выявляет крупные ошибки прогноза.

Цели использования предиктивной аналитики в управлении потоками и очередями можно условно разделить на операционные и стратегические. Операционные цели включают снижение среднего времени ожидания, уменьшение вероятности образования длинных очередей и повышение уровня сервиса в часы пик. Стратегические цели связаны с оценкой сценариев развития: роста контингента, изменения расписания, модернизации инфраструктуры; для этого прогнозы нагрузки используют в моделях массового обслуживания и имитационных моделях. Например, предсказанную интенсивность потока $\lambda(t)$ можно использовать в формульных моделях очередей для оценки ожидаемого времени ожидания и длины очереди.

Общие подходы к прогнозированию нагрузки и очередей в инфраструктурных системах включают несколько крупных классов моделей.

1. Модели временных рядов. Они описывают зависимость текущего значения нагрузки от прошлых значений и сезонных компонентов. Например, простая авторегрессионная модель $AR(p)$ записывается как

$$y_t = \alpha_0 + \sum_{i=1}^p \alpha_i y_{t-i} + \varepsilon_t,$$

что позволяет учитывать автокорреляцию во временных рядах интенсивности проходов.

2. Регрессионные модели. В них нагрузка рассматривается как функция внешних факторов. Для СКУД университета это могут быть признаки вида «есть ли в данном корпусе пара в этот интервал», «номер недели семестра», «тип дня». Линейная модель, приведённая выше, даёт интерпретируемые коэффициенты: $\beta_i > 0$ означает, что соответствующий фактор увеличивает поток.
3. Модели машинного обучения. Деревья решений, случайный лес, градиентный бустинг и нейронные сети позволяют строить более сложные функции $f(X_t)$, учитывающие нелинейные эффекты и взаимодействия признаков. В общем виде прогноз можно записать как

$$\hat{y}_{t+h} = f_{\theta}(X_t),$$

где f_{θ} параметризована набором параметров θ , обучаемых по данным. Эти методы широко применяются для прогнозирования трафика в транспортных сетях, нагрузки на ИТ-инфраструктуру и клиентских потоков в сервисных системах.

Часто предиктивные модели комбинируются с теорией массового обслуживания для анализа очередей. Прогноз интенсивности входящего потока $\lambda(t)$ используется как входной параметр в модель системы с s каналами обслуживания и интенсивностью обслуживания μ . Коэффициент загрузки системы можно оценить как

$$\rho(t) = \frac{\lambda(t)}{s\mu}$$

и на этой основе вычислять ожидаемые показатели очереди и уровня сервиса для различных конфигураций ресурсов. Такой подход позволяет, например, проверить, достаточно ли двух активных турникетов в корпусе в период утреннего пик-нагрузки.

Таким образом, предиктивная аналитика в управлении потоками и очередями опирается на формальное описание временной динамики нагрузки, связь с объясняющими факторами и количественные критерии качества прогнозов. Для СКУД университета это создаёт основу для проактивного управления пропускной способностью: от обоснованного планирования режимов работы точек доступа до оценки последствий инфраструктурных изменений.

2 Модели предиктивного анализа и их применимость к СКУД университета

В контексте СКУД университета предиктивные модели используются для прогноза будущей нагрузки на точки контроля доступа и оценки риска образования очередей в различные моменты времени. На основе этих прогнозов администрация может заранее принимать решения об изменении режимов работы КПП, перераспределении потоков или корректировке расписания, что делает выбор адекватного класса моделей принципиально важным.

2.1 Классы моделей предиктивного анализа

В литературе и практике выделяется несколько основных классов моделей предиктивного анализа, которые применимы к задачам управления потоками и очередями в инфраструктурных системах:

- модели временных рядов;
- регрессионные и другие классические статистические модели;
- методы машинного обучения и интеллектуального анализа данных.

Каждый из этих классов опирается на собственные предпосылки, предъявляет разные требования к данным и обладает различными свойствами с точки зрения точности, интерпретируемости и устойчивости. Для СКУД университета важно не только качество прогноза, но и возможность объяснить результаты и внедрить модель в реальную эксплуатационную среду.

Модели временных рядов

Модели временных рядов рассматривают последовательность наблюдений $\{y_t\}$, упорядоченных во времени, и описывают зависимость текущего значения от предыдущих. В задачах СКУД в качестве временного ряда может выступать число проходов через конкретную точку доступа за фиксированный интервал времени (например, 5 или 15 минут).

Общая идея таких моделей заключается в приближении зависимости вида

$$y_t = f(y_{t-1}, y_{t-2}, \dots) + \varepsilon_t,$$

где ε_t — случайная составляющая, а функция f описывает структуру автокорреляции и, при необходимости, сезонность.

К этому классу относятся:

- авторегрессионные модели (AR);
- модели скользящего среднего (MA);
- комбинированные ARMA и ARIMA-модели;
- сезонные расширения (SARIMA и др.);
- методы экспоненциального сглаживания.

Модели временных рядов особенно хорошо работают, когда структура сезонности и тренда достаточно устойчива во времени, что соответствует регулярной работе университета в течение семестра.

Регрессионные и классические статистические модели

Регрессионные модели описывают зависимость целевой переменной от набора объясняющих факторов, которые в задачах СКУД естественным образом связаны с особенностями учебного процесса. В общем виде линейная регрессионная модель может быть записана как

$$y_t = \beta_0 + \sum_{i=1}^k \beta_i x_{t,i} + \varepsilon_t,$$

где y_t — количество проходов за интервал t , $x_{t,i}$ — значения признаков (день недели, наличие занятий, тип дня), β_i — коэффициенты влияния факторов.

К этой группе также относятся:

- полиномиальные регрессионные модели;
- модели с взаимодействием признаков;
- обобщённые линейные модели для счётных данных (пуассоновская, отрицательно-биномиальная регрессия).

Регрессионный подход позволяет явно учитывать влияние конкретных факторов, что важно для обоснования управленческих решений (например, оценки влияния изменения расписания на нагрузку).

Методы машинного обучения

Методы машинного обучения используют более гибкие функциональные формы и способны моделировать сложные нелинейные зависимости и взаимодействия признаков. В общем виде прогноз можно представить как

$$\hat{y}_t = f_{\theta}(X_t),$$

где X_t — вектор признаков, а f_{θ} — параметризованная модель (дерево решений, ансамбль деревьев, нейронная сеть и др.).

К распространённым методам относятся:

- деревья решений;
- случайный лес;
- градиентный бустинг деревьев;
- простые и глубокие нейронные сети.

Эти методы особенно полезны при наличии большого объёма данных и сложной структуры факторов, когда линейные модели уже не дают удовлетворительного качества прогноза.

Сводная характеристика классов моделей

Для удобства основные свойства классов моделей можно представить в виде таблицы.

Класс моделей	Основная идея	Плюсы	Минусы	Типичные данные
Модели временных рядов	Зависимость от прошлых значений и сезонности	Простота, учёт сезонности	Чувствительность к структурным сдвигам	Ряды y_t во времени

Регрессионные модели	Зависимость от объясняющих факторов	Интерпретируемость, простота	Ограниченност линейными связями	X_t, y_t
Методы машинного обучения	Гибкая аппроксимация функции $f(X)$	Высокая точность, нелинейность	Требовательны к данным, сложны в интерпретации	Большие выборки

Для задач СКУД университета на практике часто оказывается целесообразным комбинированный подход, в котором базовые прогнозы строятся простыми моделями, а более сложные методы применяются для уточнения и анализа специфических сценариев.

2.2 Обзор и краткая характеристика основных моделей

На основе обозначенной классификации можно подробнее рассмотреть отдельные модели, их принцип работы и типичные области применения, близкие по характеру к задаче прогнозирования пропускной способности СКУД.

Модели временных рядов

1. AR-модели (авторегрессия).

В авторегрессионной модели порядка p текущее значение ряда выражается через линейную комбинацию предыдущих значений:

$$y_t = \alpha_0 + \sum_{i=1}^p \alpha_i y_{t-i} + \varepsilon_t.$$

Такие модели учитывают автокорреляцию в данных и подходят для задач, где значения в соседние моменты времени сильно взаимосвязаны. В случае СКУД это характерно для коротких интервалов времени внутри одного дня.

2. ARMA и ARIMA-модели.

ARMA-модели комбинируют авторегрессию и скользящее среднее, учитывая как прошлые значения, так и прошлые ошибки прогноза. ARIMA-подход дополнительно включает интегрирование (разности), позволяющее моделировать нестационарные ряды с трендом. Эти модели широко используются в экономике, телекоммуникациях и других областях для краткосрочного прогноза нагрузок и временных рядов.

3. Сезонные модели (SARIMA и др.).

Для учёта регулярных циклов (например, недельной повторяемости) используются сезонные расширения, где в модель добавляются сезонные авторегрессионные и скользящие компоненты с лагом, кратным сезону. В условиях университета это позволяет моделировать типичную недельную структуру нагрузки на КПП: высокая нагрузка по будням утром и вечером, снижение в выходные.

4. Методы экспоненциального сглаживания.

Эти методы строят прогноз на основе взвешенного среднего прошлых значений, где недавние данные получают больший вес. Они хорошо подходят для «онлайнового» обновления прогнозов и применяются в прогнозировании спроса, трафика и других показателей. Для СКУД их можно использовать для оперативного прогнозирования нагрузки в ближайшие интервалы времени.

Регрессионные модели

1. Линейная регрессия.

Простая линейная регрессия предполагает линейную зависимость между целевой переменной и набором признаков. В контексте СКУД можно включать в модель признаки:

- день недели;
- номер пары или временной слот;
- количество запланированных занятий в корпусе;
- признак сессии или учебного периода;

- индикатор массовых мероприятий.

По оценённым коэффициентам β_i можно судить, насколько каждый фактор влияет на среднюю нагрузку, что делает модель удобной для объяснения и обсуждения с администрацией университета.

2. Полиномиальные и взаимодействующие модели.

При наличии нелинейных эффектов (например, насыщения потока при определённой нагрузке) могут использоваться полиномиальные регрессии или модели с произведениями признаков. Это позволяет учесть взаимодействие факторов, например, особое поведение потоков в сочетании «понедельник + первая неделя семестра».

3. Обобщённые линейные модели (GLM) для счётных данных.

Так как количество проходов за интервал является счётной величиной, для него естественны модели с пуассоновским или отрицательно-биномиальным распределением. В таких моделях используется лог-связь:

$$\log(\mathbb{E}[y_t]) = \beta_0 + \sum_{i=1}^k \beta_i x_{t,i},$$

что обеспечивает неотрицательность предсказаний и более реалистичное описание распределения данных. Аналогичные подходы применяются в задачах моделирования потоков клиентов и интенсивности событий в различных сервисных системах.

Методы машинного обучения

1. Деревья решений.

Дерево решений последовательно делит пространство признаков на области с относительно однородными значениями целевой переменной на основе правил вида «если–то». Например, модель может выработать правило: «если день недели — понедельник и число пар в корпусе больше N , то прогнозируемая нагрузка высокая». Деревья удобны своей интерпретируемостью, но одиночные деревья склонны к переобучению и нестабильности.

2. Случайный лес.

Случайный лес представляет собой ансамбль деревьев решений, обученных на разных подвыборках данных и подмножествах признаков. Прогноз получается путём усреднения прогнозов отдельных деревьев, что повышает точность и устойчивость. Этот подход широко используется для задач прогнозирования спроса, клиентских потоков и других показателей, требующих учёта большого числа факторов.

3. Градиентный бустинг деревьев.

Методы градиентного бустинга строят последовательность деревьев, каждое из которых исправляет ошибки предыдущих. Такие модели часто демонстрируют высокое качество прогнозирования при достаточно гибкой настройке, но могут быть более требовательны к ресурсам и сложнее в конфигурации. В задачах прогнозирования потоков людей они применяются для учёта сложных нелинейных зависимостей и сезонно-календарных эффектов.

4. Нейронные сети.

Искусственные нейронные сети, включая рекуррентные и свёрточные архитектуры для временных рядов, позволяют моделировать сложные временные зависимости и паттерны поведения пользователей. При достаточном объёме данных они могут обеспечить высокую точность прогнозов нагрузки на СКУД, однако их внедрение требует высокой компетенции и сопровождения.

Во многих инфраструктурных приложениях наилучшие результаты даёт гибридный подход, когда более простые и интерпретируемые модели используются как базовый инструмент, а сложные алгоритмы машинного обучения применяются для детального анализа и повышения точности прогнозов на критически важных участках. Для СКУД университета это означает возможность сочетать, например, регрессионные модели для регулярных прогнозов с ансамблевыми методами для анализа пиковых нагрузок и нестандартных ситуаций.

2.3 Критерии оценки и сравнения моделей для задач СКУД

При выборе моделей предиктивного анализа для задач оптимизации пропускной способности СКУД университета необходимо опираться не на один, а сразу на несколько критериев качества и пригодности модели к эксплуатации. Модель должна не только демонстрировать приемлемую точность прогноза, но и быть интерпретируемой, устойчивой к изменениям данных и реалистичной с точки зрения требований к объёму и качеству исходной информации.

К основным критериям оценки относятся:

- точность прогнозирования;
- интерпретируемость и объяснимость результатов;
- устойчивость (робастность) к шумам и изменениям условий;
- требования к данным и вычислительным ресурсам.

Точность прогнозирования

Точность характеризует, насколько близки прогнозируемые значения к фактическим. В задачах прогнозирования числа проходов через точки доступа используются стандартные метрики ошибок:

- средняя абсолютная ошибка (*MAE*):

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|,$$

- среднеквадратичная ошибка (*RMSE*):

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

- средняя абсолютная процентная ошибка (*MAPE*) при ненулевых значениях y_i .

Для СКУД важно учитывать не только среднюю ошибку за длительный период, но и максимальные отклонения в пиковые моменты, когда небольшое недооценивание потока может привести к значительным очередям. Поэтому при сравнении моделей целесообразно анализировать ошибки отдельно для интервалов с высокой нагрузкой.

Интерпретируемость и объяснимость

Интерпретируемость означает возможность понять, как модель принимает решения, какие факторы наиболее сильно влияют на прогноз и почему в определённые моменты времени ожидается рост или снижение нагрузки. Для университета это важно, потому что решения на основе модели должны быть понятны административному персоналу и, возможно, объяснимы студентам и сотрудникам.

По уровню интерпретируемости модели условно можно расположить следующим образом:

1. высокий уровень: линейные и обобщённые линейные регрессии, простые деревья решений;

2. средний уровень: ансамбли деревьев (случайный лес, бустинг) с анализом важности признаков;
3. низкий уровень: сложные нейронные сети, гибридные модели.

Чем выше интерпретируемость, тем легче обосновать организационные изменения: например, перенос части занятий в другой корпус или изменение числа открытых турникетов в конкретные интервалы.

Устойчивость (робастность)

Устойчивость модели отражает её способность сохранять приемлемое качество при наличии шума, выбросов и умеренных изменений структуры потоков. В реальных условиях работы СКУД возможны:

- технические сбои (отсутствие части записей в логах);
- разовые аномальные события (крупное мероприятие, внеплановый ремонт);
- постепенное изменение поведения пользователей (введение новых правил прохода, смена расписания).

Модель должна:

- не «ломаться» из-за единичных аномальных дней;
- адаптироваться через переобучение к новым условиям;
- не переобучаться на кратковременные, нерепрезентативные участки данных.

Обычно более простые модели (регрессия, сглаженные ряды) менее склонны к переобучению, тогда как сложные алгоритмы машинного обучения требуют аккуратной настройки и регулярной валидации.

Требования к данным и вычислительным ресурсам

Этот критерий особенно важен для университетской среды, где:

- объём исторических данных может быть ограничен;
- логирование могло начинаться сравнительно недавно;
- уровень автоматизации и мощности серверов может быть невысоким.

Сравнительно:

- модели временных рядов и простые регрессии требуют умеренного объёма данных и хорошо работают при корректной агрегации (например, несколько семестров логов по 5–15-минутным интервалам);
- ансамбли деревьев и нейросетевые модели требуют существенно большего числа наблюдений, качественного набора признаков и могут предъявлять повышенные требования к вычислительным ресурсам.

Для практического использования важно, чтобы модель можно было обучать и переобучать на имеющейся инфраструктуре без значительных затрат.

Таблица критериев для основных классов моделей

Класс моделей	Точность (типично)	Интерпретируемость	Устойчивость	Требования к данным
Временные ряды	Средняя– высокая	Средняя	Средняя	Умеренные
Регрессионные модели	Средняя	Высокая	Высокая	Низкие– умеренные
Машинное обучение	Высокая	Низкая–средняя	Зависит от настройки	Высокие

Такая сводка позволяет видеть, что выбор модели — это компромисс между точностью, понятностью и затратами на реализацию.

2.4 Оценка применимости моделей для оптимизации пропускной способности СКУД университета

Применимость конкретных классов моделей к задаче оптимизации пропускной способности СКУД определяется сочетанием характеристик данных и особенностей режимов работы университета. Потоки пользователей формируются под влиянием расписания занятий, сессий, календаря мероприятий, а также организационных изменений (например, смены правил прохода или открытия новых корпусов).

Особенности данных и процессов в СКУД университета

Для оценки моделей полезно выделить характерные свойства данных:

- выраженная суточная и недельная сезонность (пики утром и в начале пар, снижение днём и вечером, отличия будней и выходных);
- семестровая структура (начало семестра, середина, сессия, каникулы);
- наличие резких пиков при массовых мероприятиях;
- возможная неполнота и шум в логах (сбои оборудования, обход СКУД).

Также важно учитывать управленические задачи:

1. прогноз нагрузки на ближайшие часы для оперативного управления;
2. оценка ожидаемой нагрузки при изменении расписания или структуры корпусов;
3. анализ типичных «узких мест» и сценариев перегрузки.

Применимость моделей временных рядов

Модели временных рядов хорошо соответствуют задачам краткосрочного прогноза при относительно стабильной структуре расписания.

Их преимущества:

- естественное описание сезонности (суточной, недельной);
- возможность быстрого обновления моделей при поступлении новых данных;
- умеренные требования к ресурсам и данным.

Для СКУД это означает, что

- можно прогнозировать нагрузку на турникеты на ближайшие часы/дни с учётом типичных паттернов;
- модели подходят для регулярной эксплуатационной задачи «завтрашний/следующий день» при неизменном расписании.

Ограничения:

- чувствительность к структурным изменениям (резкое изменение расписания, необычные события);
- слабый учёт внешних факторов, если они не включены в модель в виде регрессорных компонент.

Поэтому чисто «рядовые» модели лучше применять в сочетании с дополнительной информацией (календарь, расписание), либо использовать их как базовый слой прогнозирования.

Применимость регрессионных моделей

Регрессионные модели особенно хорошо подходят для задач, где ключевую роль играют понятные факторы — расписание, тип дня, количество занятий в корпусе

Их сильные стороны:

- высокая интерпретируемость: виден вклад каждого фактора;
- удобство при анализе сценариев «что будет, если»;
- устойчивость при умеренном объёме данных.

В задачах СКУД регрессионная модель может отвечать на вопросы:

- как изменится средняя нагрузка на входной КПП, если в корпусе добавить ещё две пары вечером;
- насколько увеличивается поток в дни экзаменов по сравнению с обычными учебными днями;
- как распределить занятия по корпусам, чтобы выровнять нагрузки.

Ограничения:

- линейность базовой формы (если не использовать полиномиальные и взаимодействующие термы);
- необходимость предварительного выбора значимых факторов;
- ограниченная способность описывать сложные нелинейные эффекты.

Тем не менее, в условиях университета регрессионные модели часто являются оптимальным компромиссом между точностью и понятностью.

Применимость методов машинного обучения

Методы машинного обучения обладают высокой потенциальной точностью, особенно при сложной структуре данных и наличии множества факторов. Они могут:

- выявлять нелинейные зависимости и взаимодействия признаков;

- автоматически «подстраиваться» под сложные паттерны спроса;
- использовать большой объём входной информации (расписание, тип занятий, особенности групп и т.п.).

В применении к СКУД университета такие модели особенно полезны:

- при наличии нескольких лет детализированных логов;
- при сложной структуре расписания и разнообразии типов мероприятий;
- когда требуется максимальная точность прогнозирования пиков.

Однако существуют существенные ограничения:

- требовательность к объёму и качеству данных;
- необходимость квалифицированной настройки и сопровождения;
- сниженная интерпретируемость, что затрудняет объяснение решений.

Это делает методы машинного обучения более уместными на этапах, когда базовая система предиктивного анализа уже отлажена, а университет готов вкладываться в дальнейшее повышение качества моделей.

Сравнительная оценка применимости

С учётом описанных особенностей, применимость классов моделей к задачам оптимизации пропускной способности СКУД можно суммарно представить следующим образом.

Класс моделей	Условие, когда подходит для задач СКУД	Основная роль
Модели временных рядов	Есть устойчивая сезонность, стабильное расписание	Краткосрочный прогноз нагрузки
Регрессионные модели	Есть расписание и календарные факторы, важна интерпретация	Анализ влияния факторов, сценарии
Машинное обучение	Много данных, сложные паттерны, требуется точные прогнозы	Уточнение прогнозов, сложные случаи

Для типичного университета с ограниченными ресурсами рационально начинать с сочетания моделей временных рядов и регрессионных подходов, постепенно дополняя их методами машинного обучения по мере накопления данных и опыта. Такой поэтапный подход позволяет получать практический эффект от предиктивной аналитики уже на ранних этапах, не перегружая систему излишней сложностью.

2.5 Рекомендации по выбору моделей для практического использования

При выборе моделей предиктивного анализа для оптимизации пропускной способности СКУД университета следует исходить из того, что цель работы — использовать уже существующие методы, не создавая собственных алгоритмов, и при этом получить практически полезный инструмент для поддержки управленческих решений. Важно найти баланс между точностью прогнозов, сложностью внедрения и возможностью объяснить результаты заинтересованным сторонам.

Учитывая рассмотренные классы моделей, наиболее перспективным подходом для вузовской среды выглядит многоуровневая стратегия, основанная на сочетании сравнительно простых статистических моделей и доступных реализаций методов машинного обучения в виде готовых библиотек и программных продуктов. На базовом уровне целесообразно использовать модели временных рядов и регрессионные модели, которые широко реализованы в стандартных аналитических пакетах и не требуют значительных вычислительных ресурсов. Они позволяют относительно быстро развернуть систему прогнозирования нагрузки на КПП, опираясь на имеющиеся логи СКУД и расписание занятий.

Модели временных рядов (ARIMA, сезонные модификации, экспоненциальное сглаживание) подходят для регулярного краткосрочного прогнозирования количества проходов на основе исторических паттернов суточной и недельной сезонности. Их можно применять для планирования режимов работы входных точек на ближайшие дни и недели, особенно если структура расписания относительно стабильна. В то же время регрессионные и обобщённые линейные модели позволяют включить в анализ календарные и организационные факторы, что делает их удобными для оценки сценариев «что будет, если» при изменении расписания, перераспределении занятий по корпусам или планировании массовых мероприятий.

Методы машинного обучения целесообразно рассматривать как следующий этап развития системы аналитики, когда накоплен достаточный объём данных и есть потребность повысить точность прогнозов или выявить сложные закономерности, неочевидные при линейном подходе. В этом случае можно использовать готовые реализации деревьев решений, случайного леса и градиентного бустинга в распространённых библиотеках, не создавая свои алгоритмы «с нуля». Такие модели имеют смысл внедрять точечно: для анализа наиболее проблемных КПП, для прогноза нагрузок в периоды с нестандартной структурой (сессии, крупные мероприятия), а также для выявления нетривиальных комбинаций факторов, приводящих к перегрузкам.

Практически целесообразно разделить задачи на две группы: эксплуатационные и планово-аналитические. Для эксплуатационных задач (ежедневный прогноз нагрузки, оперативное управление) достаточно, как правило, комбинации моделей временных рядов с ограниченным набором факторов, реализованных в типовых BI- или статистических системах. Для планово-аналитических задач (оценка эффектов от изменений расписания, сценарии роста контингента, модернизация входной инфраструктуры) более удобны регрессионные модели и, при наличии данных, ансамблевые методы машинного обучения, позволяющие моделировать различные сценарии без вмешательства в реальную работу СКУД.

Стоит подчеркнуть важность поэтапного внедрения. Рекомендуется сначала реализовать пилотный проект на одном корпусе или группе точек доступа, используя простые и хорошо интерпретируемые модели. На этом этапе проверяется качество прогнозов, настраиваются процессы сбора и очистки данных, отрабатывается взаимодействие между ИТ-службой и администрацией. Лишь после подтверждения практической полезности и устойчивости решений имеет смысл переходить к более сложным моделям и расширять охват на всю инфраструктуру университета.

С учётом того, что данная работа ориентирована на анализ уже существующих моделей предиктивного анализа, целесообразно акцентировать внимание на использовании готовых программных средств и библиотек, реализующих соответствующие методы. К таким средствам относятся стандартные статистические пакеты, системы бизнес-аналитики, а также открытые программные решения, содержащие реализации алгоритмов работы с временными рядами, регрессионных моделей и моделей машинного обучения.

В обобщённом виде следует ориентироваться на следующую схему использования моделей предиктивного анализа: применять модели временных рядов для базового краткосрочного прогноза нагрузок с учётом суточной и недельной сезонности; использовать регрессионные и обобщённые линейные модели для анализа влияния расписания и календарных факторов, а также для проведения сценарных расчётов; при наличии достаточного объёма данных и необходимых ресурсов подключать ансамблевые методы машинного обучения с целью уточнения прогнозов и выявления более сложных закономерностей в динамике потоков через точки контроля доступа. Такой подход позволяет опираться на существующие модели и программные решения, постепенно повышая уровень аналитической зрелости СКУД университета и обеспечивая практический эффект без необходимости разработки собственных алгоритмов предиктивного анализа.

ЗАКЛЮЧЕНИЕ

В ходе работы была рассмотрена предметная область функционирования СКУД в образовательных учреждениях, проанализированы особенности формирования потоков пользователей и факторы, влияющие на возникновение очередей и перегрузок на контрольно-пропускных пунктах. Особое внимание уделялось теоретическим аспектам понятия пропускной способности, показателям эффективности работы КПП и возможностям количественного описания этих характеристик с использованием аппарата теории массового обслуживания и соответствующих метрик.

Был выполнен обзор основных классов моделей предиктивного анализа, включающий модели временных рядов, регрессионные модели и методы машинного обучения, а также рассмотрены их концептуальные особенности, достоинства и ограничения применительно к задачам управления потоками и очередями. Показано, что модели временных рядов позволяют эффективно учитывать суточную и недельную сезонность нагрузок и являются удобным инструментом для краткосрочного прогнозирования интенсивности проходов при относительно стабильной структуре учебного процесса. Регрессионные и обобщённые линейные модели обеспечивают высокий уровень интерпретируемости и дают возможность явно учитывать влияние календарных и организационных факторов, что особенно важно при анализе сценариев изменения расписания и структуры учебного процесса. Методы машинного обучения, такие как ансамбли деревьев и нейронные сети, обладают высоким потенциалом по точности прогнозирования, однако предъявляют повышенные требования к объёму данных, вычислительным ресурсам и квалификации персонала.

На основе выделенных критериев сравнения моделей — точности, интерпретируемости, устойчивости и требований к данным — проведена оценка их пригодности для использования в условиях СКУД университета. Показано, что для большинства практических задач в вузовской среде целесообразно применять комбинированный подход, в котором базовые прогнозы строятся на основе моделей временных рядов и регрессионных моделей, а методы машинного обучения используются для уточнения результатов и анализа сложных или нетипичных ситуаций. Такой подход позволяет обеспечить баланс между качеством прогнозов и сложностью внедрения, а также опираться преимущественно на готовые программные средства и библиотеки, не разрабатывая собственные алгоритмы предиктивного анализа.

В работе сформулированы практические рекомендации по выбору и применению существующих моделей предиктивного анализа для задач оптимизации пропускной способности СКУД университета. Предлагается ориентироваться на использование моделей временных рядов для регулярного краткосрочного прогнозирования нагрузок на КПП с учётом сезонности, регрессионных и обобщённых линейных моделей — для анализа влияния расписания и календарных факторов, а также проведения сценарных расчётов, и ансамблевых методов машинного обучения — при наличии достаточного объёма исторических данных и необходимости повышения точности прогнозов. Реализация предложенного подхода может способствовать снижению очередей и времени ожидания на точках контроля доступа, более рациональному использованию инфраструктуры, а также повышению общего уровня сервиса для студентов и сотрудников университета. Вместе с тем результаты работы могут служить основой для дальнейших исследований, связанных с пилотным внедрением конкретных моделей на реальных данных СКУД, сравнением их эффективности в условиях эксплуатации и возможной адаптацией более сложных методов предиктивного анализа по мере развития информационной инфраструктуры вуза.

СПИСОК ИСПОЛЬЗУЕМЫХ ИСТОЧНИКОВ

1. Методы краткосрочного прогнозирования транспортных потоков на основе больших данных // Вестник ВГЛТУ. — 2024. — № 6. — URL: https://bibl.vgltu.ru/ru/nauka/conference_article/11680/view (дата обращения: 28.12.2025).[1]
2. Временные ряды в прогнозировании спроса, нагрузки на КЦ и других бизнес-задачах // Habr. — 2019. — 25 ноября. — URL: <https://habr.com/ru/articles/477206/> (дата обращения: 28.12.2025).[2]
3. ARIMA – модель прогнозирования значений трафика [Электронный ресурс] // Журнал информационных технологий, компьютерных систем. — 2011. — № 2. — URL: http://www.isa.ru/jitcs/images/documents/2011-02/41_49.pdf (дата обращения: 28.12.2025).[3]
4. 5 алгоритмов регрессии в машинном обучении, о которых вам стоит знать // Habr. — 2021. — 21 января. — URL: <https://habr.com/ru/companies/vk/articles/513842/> (дата обращения: 28.12.2025).[4]
5. Теория массового обслуживания // Less.works. — 2024. — URL: https://less.works/ru/less/principles/queueing_theory (дата обращения: 28.12.2025).[5]
6. Помехоустойчивость систем контроля и управления доступом в зданиях при воздействии импульсных помех электромагнитного излучения : дис. ... канд. техн. наук [Электронный ресурс] — URL: <https://www.dissercat.com/content/pomekhoustoichivost-sistem-kontrollya-i-upravleniya-dostupom-v-zdaniya-pri-vozdeistvii-impuls> (дата обращения: 28.12.2025).[6]
7. Интегрированные системы – новый уровень безопасности // Secuteck.ru. — 2021. — 10 ноября. — URL: <https://www.secuteck.ru/articles/integrirovannye-sistemy-novyj-uroven-bezopasnosti> (дата обращения: 28.12.2025).[7]

8. СКУД с учетом рабочего времени // ControlGate. — URL: <https://controlgate.ru/news/sekret-produktivnosti-zumerov-na-rabote/> (дата обращения: 28.12.2025).[8]

9. Прогнозирование денежных потоков при планировании развития компаний [Электронный ресурс] // НИУ ВШЭ. — 2024. — URL: <https://www.hse.ru/edu/vkr/219399340> (дата обращения: 28.12.2025).[9]

10. Дуброва Т.А. Статистические методы прогнозирования временных рядов // Журнал информационных технологий, компьютерных систем. — 2011. — № 2. — С. 41–49.[10]

11. Система предиктивной аналитики для оптимизации работы инфраструктуры [Электронный ресурс] // MLSD2019. — URL: https://mlsd2019.ipu.ru/proceedings_1/section_7/566-570.pdf (дата обращения: 28.12.2025).[11]

12. Предиктивная аналитика: этапы, методы, польза бизнесу // Decosystems. — 2024. — URL: <https://www.decosystems.ru/prediktivnaya-analitika-cto-eto/> (дата обращения: 28.12.2025).[12]

13. Контроль и мониторинг промышленного оборудования с использованием предиктивной аналитики // ISUP. — 2017. — URL: <https://isup.ru/articles/2/13235/> (дата обращения: 28.12.2025).[13]

14. ГОСТ Р 56938-2016. Системы контроля и управления доступом. Общие технические требования. — М.: Стандартинформ, 2016. — 24 с.[14]